





DS-003 – Análises básicas de dados para área da saúde I

Prof. Marcelo Henklain

Aula 02 – Árvores de Decisão






Introdução à Árvore de Decisão (Classificação)

Árvore de Decisão

Esta árvore nos permite **classificar** quem gosta ou não de DS.



Árvore de Decisão

Fraude de cartão de vacina

Índice	Brasileiro?	Vacinado_Covid?	Idade	Fraude?
1	Sim	Sim	12	Não
2	Não	Não	33	Sim
3	Sim	Sim	18	Não
4	Sim	Não	22	Sim
5	Não	Não	18	Não

Como **saber** qual deve ser o nó raiz?

Árvore de Decisão

Fraude de cartão de vacina

Índice	Brasileiro?	Vacinado_Covid?	Idade	Fraude?
0	Sim	Sim	12	Não
1	Não	Não	33	Sim
2	Sim	Sim	18	Não
3	Sim	Não	22	Sim
4	Não	Não	18	Não

Variáveis ‘Brasileiro?’ e ‘Vacinado_Covid?’ são **categóricas** e Idade é **escalar**.

Índice de Impureza de Gini


$$1 - \sum_{i=1}^n p_i^2$$

$$p = \frac{\text{quantidade de uma classe}}{\text{total das classes}}$$

É impuro todo nó que, quando usado para classificar, possui mais de uma classe. Com o Gini, queremos encontrar o **menor grau de impureza**.

Árvore de Decisão


O nó da esquerda (verde) é **impuro** porque tem casos nas classes de Sim e Não.



	Índice	Brasileiro?	Fraude?
●	0	Sim	Não
	1	Não	Sim
●	2	Sim	Não
●	3	Sim	Sim
	4	Não	Não

Árvore de Decisão

O nó da direita (vermelho) é **impuro** porque tem casos nas classes de Sim e Não.



Índice	Brasileiro?	Fraude?
0	Sim	Não
1	Não	Sim
2	Sim	Não
3	Sim	Sim
4	Não	Não

Árvore de Decisão

Calculamos o Gini de **cada nó** e depois realizamos uma soma ponderada.

$$\text{Gini} = 1 - \sum_{i=1}^n p_i^2$$

Brasileiro?

Fraude

Sim	Não
1	2

Gini da Folha Verde

$$1 - (\text{prob. Sim})^2 - (\text{prob. Não})^2$$

$$1 - (1/3)^2 - (2/3)^2$$

$$1 - (0,33)^2 - (0,67)^2$$

$$1 - 0,11 - 0,44$$

$$\text{Gini} = 0,45$$

Fraude

Sim	Não
1	1

Gini da Folha Vermelha

$$1 - (\text{prob. Sim})^2 - (\text{prob. Não})^2$$

$$1 - (1/2)^2 - (1/2)^2$$

$$1 - (0,50)^2 - (0,50)^2$$

$$1 - 0,25 - 0,25$$

$$\text{Gini} = 0,50$$

Árvore de Decisão

O Gini total é a **soma ponderada** das duas folhas.

$$\text{Peso} = \frac{\text{Total de itens na folha}}{\text{Total de itens nas duas folhas}}$$

Brasileiro?

Fraude	
Sim	Não
1	2

Gini da Folha Verde

Gini = 0,45

Peso = 3/5

Peso = 0,60

Fraude	
Sim	Não
1	1

Gini da Folha Vermelha

Gini = 0,50

Peso = 2/5


Peso = 0,40

$$\text{Gini Total} = 0,60 * 0,45 + 0,40 * 0,50$$

$$0,27 + 0,20$$

$$\text{Gini Total} = 0,47$$

Árvore de Decisão



Índice	Vacinado_Covid?	Fraude?
0	Sim	Não
1	Não	Sim
2	Sim	Não
3	Não	Sim
4	Não	Não

Árvore de Decisão

Encontramos um nó **totalmente puro**, com
Gini = 0.

Vacinado_Covid?

Fraude	
Sim	Não
0	2

Gini da Folha Verde

$$1 - (\text{prob. Sim})^2 - (\text{prob. Não})^2$$

$$1 - (0/2)^2 - (2/2)^2$$

$$1 - (0)^2 - (1)^2$$

$$1 - 0 - 1$$

$$\text{Gini} = 0,00$$

Fraude	
Sim	Não
2	1

Gini da Folha Vermelha

$$1 - (\text{prob. Sim})^2 - (\text{prob. Não})^2$$

$$1 - (2/3)^2 - (1/3)^2$$

$$1 - (0,67)^2 - (0,33)^2$$

$$1 - 0,44 - 0,11$$

$$\text{Gini} = 0,45$$

Árvore de Decisão

Aqui, mais uma vez,
calculamos o **Gini total**.

Vacinado_Covid?

Fraude	
Sim	Não
0	2

Gini da Folha Verde

Gini = 0,00

Peso = 2/5

Peso = 0,40

Fraude	
Sim	Não
2	1

Gini da Folha Vermelha

Gini = 0,45

Peso = 3/5

Peso = 0,60


$$\text{Gini Total} = 0,40 * 0,00 + 0,60 * 0,45$$

$$0,00 + 0,27$$

$$\text{Gini Total} = 0,27$$

Árvore de Decisão


Trabalhar com valores **contínuos** é mais complicado.



Índice	Idade	Fraude?
0	12	Não
1	33	Sim
2	18	Não
3	22	Sim
4	18	Não

Árvore de Decisão


1º) Começamos organizando em ordem crescente.



Índice	Idade	Fraude?
0	12	Não
2	18	Não
4	18	Não
3	22	Sim
1	33	Sim

Árvore de Decisão

2º) Calculamos as médias dos valores adjacentes da variável contínua.



Índice	Idade		Fraude?
0	12	15,00	Não
1	18	18,00	Não
2	18	20,00	Não
3	22	27,50	Sim
4	33		Sim

Árvore de Decisão

3º) Calculamos o Gini para **cada média**. Entre empates, podemos escolher qualquer um.

Índice	Idade		Fraude?
0	12	15,00	Não
1	18	18,00	Não
2	18	20,00	Não
3	22	20,00	Sim
4	33	27,50	Sim

Idade $\leq 15,00$

Fraude

Sim	Não
0	1

Gini = 0,00
Peso = 0,20

Fraude

Sim	Não
2	2

Gini = 0,50
Peso = 0,80

Gini = 0,40

Idade $\leq 20,00$

Fraude

Sim	Não
0	3

Gini = 0,00
Peso = 0,60

Fraude

Sim	Não
2	0

Gini = 0,00
Peso = 0,40

Gini = 0,00

Idade $\leq 18,00$

Fraude

Sim	Não
0	3

Gini = 0,00
Peso = 0,60

Fraude

Sim	Não
2	0

Gini = 0,00
Peso = 0,40

Gini = 0,00

Idade $\leq 27,50$

Fraude

Sim	Não
1	3


Gini = 0,38
Peso = 0,80

Fraude

Sim	Não
1	0


Gini = 0,00
Peso = 0,20

Gini = 0,30





Árvore de Decisão

4º) Após definir o nó raiz, se ainda existir impureza, **podemos continuar** com o mesmo procedimento já aplicado.



5º) Por fim, precisamos indicar as **categorias** das folhas.



Encontramos resultados similares àqueles do algoritmo do **Scikit-Learn**.

Árvore de Decisão

Fraude de cartão de vacina

Índice	Brasileiro?	Vacinado_Covid?	Idade	Fraude?
5	Sim	Não	20,0	Não
6	Não	Não	20,5	Sim

Idade $\leq 20,00$

NÃO
Fraude Cartão

SIM
Fraude Cartão

Idade $\leq 20,00$

NÃO
Fraude Cartão

SIM
Fraude Cartão

Novos dados foram obtidos!

Atenção

Se encontrarmos folhas com apenas 1 caso, isso pode ser um indicador de **overfitting**. Pense: se apenas um caso foi encontrado, pode ser que isso não se repita para além dos dados de treino. Uma estratégia para lidar com tal problema é **limitar a profundidade** da árvore. Mas **existem outras estratégias possíveis**.