





DS-003 – Análises básicas de dados para área da saúde I

Prof. Marcelo Henklain

Aula 03 – Floresta Aleatória





Introdução à Técnica de Bagging em Árvores de Decisão

Bagging = Bootstrap (reamostragem) + Agreggating
Random Forest é uma técnica de bagging com ADs.
Vamos criar uma floresta aleatória!

Dataset Original

Índice	Brasileiro?	Vacinado_Covid?	Idade	Fraude?
1	Sim	Sim	12	Não
2	Não	Não	33	Sim
3	Sim	Sim	18	Não
4	Sim	Não	22	Sim
5	Não	Não	18	Não

Dataset Bootstrapped

Índice	Brasileiro?	Vacinado_Covid?	Idade	Fraude?
1	Sim	Sim	12	Não
5	Não	Não	18	Não
4	Sim	Não	22	Sim
3	Sim	Sim	18	Não
5	Não	Não	18	Não

Passo 1: Bootstrap

Sorteia uma linha dos dados e repete esse processo pelo número de vezes correspondente ao tamanho do dataset.

AD com Bagging

AD com novo dataset

???

Dataset Bootstrapped


Índice	Brasileiro?	Vacinado_Covid?	Idade	Fraude?
1	Sim	Sim	12	Não
5	Não	Não	18	Não
4	Sim	Não	22	Sim
3	Sim	Sim	18	Não
5	Não	Não	18	Não

Qual das duas variáveis selecionadas aleatoriamente realiza o melhor trabalho de redução da impureza?

Passo 2: Criar 1 AD

Cria 1 AD usando o dataset bootstrapped, mas somente com um subconjunto aleatório de variáveis (colunas) a cada passo.

AD com novo dataset



Supondo que seja 'Brasileiro?', vamos selecionar aleatoriamente mais X colunas remanescentes e repetir tudo.







Dataset Bootstrapped

Índice	Brasileiro?	Vacinado_Covid?	Idade	Fraude?
1	Sim	Sim	12	Não
5	Não	Não	18	Não
4	Sim	Não	22	Sim
3	Sim	Sim	18	Não
5	Não	Não	18	Não

Passo 2: Criar 1 AD

Cria 1 AD usando o dataset bootstrapped, mas somente com um subconjunto aleatório de variáveis (colunas) a cada passo.

AD com Bagging



Passo 3: Repetir tudo
Criam-se novos datasets bootstrapped e novas ADs. Isso pode ser feito **centenas de vezes!**

Dataset Original

Índice	Brasileiro?	Vacinado_Covid?	Idade	Fraude?
1	Sim	Sim	12	Não
2	Não	Não	33	Sim
3	Sim	Sim	18	Não
4	Sim	Não	22	Sim
5	Não	Não	18	Não

Out-of-Bag Dataset

Dataset Bootstrapped

Índice	Brasileiro?	Vacinado_Covid?	Idade	Fraude?
1	Sim	Sim	12	Não
5	Não	Não	18	Não
4	Sim	Não	22	Sim
3	Sim	Sim	18	Não
5	Não	Não	18	Não

Passo 4: Testar

Ao sortear dados, podemos ter duplicações. Geralmente, 1/3 dos dados **não entram** no dataset bootstrapped.

Dataset Original

Índice	Brasileiro?	Vacinado_Covid?	Idade	Fraude?
1	Sim	Sim	12	Não
2	Não	Não	33	Sim
3	Sim	Sim	18	Não
4	Sim	Não	22	Sim
5	Não	Não	18	Não

Out-of-Bag Dataset

Dataset Bootstrapped


Índice	Brasileiro?	Vacinado_Covid?	Idade	Fraude?
1	Sim	Sim	12	Não
5	Não	Não	18	Não
4	Sim	Não	22	Sim
3	Sim	Sim	18	Não
5	Não	Não	18	Não

Passo 4: Testar

Temos que **quantificar** as classificações corretas e incorretas dos **Out-of-Bag** nas ADs das quais não fazem parte.

Podemos medir a **acurácia da RF** pela proporção de Out-of-Bag **corretamente classificados** pelo sistema de votos de ADs das quais não fazem parte. A proporção de classificações incorretas corresponde ao **Erro de Out-of-Bag**. Podemos usar esse erro para **comparar RFs** que usem diferentes valores de variáveis no 1º Passo. O usual é começar testando a raiz quadrada do total de variáveis do dataset. Depois testamos valores abaixo e acima dessa referência.

AD com Bagging



Novo dado

Índice	Brasileiro?	Vacinado_Covid?	Idade	Fraude?
n	Sim	Sim	12	Sim

Passo 5: Usar

Pegamos um dado novo e o avaliamos com cada uma das ADs criadas em nossa floresta.







Fraude?

Sim	Não
1	0

AD com Bagging



AD com Bagging



Passo 5: Usar

Pegamos um dado novo e o avaliamos com cada uma das ADs criadas em nossa floresta.

Fraude?

Sim	Não
4	2

Fraude?	
Sim	Não
4	2

Ganha a classificação que recebeu mais votos!

Atenção

A técnica de *bagging* é um tipo de aprendizado por agrupamento e se destaca pela redução de variância. Existe também a técnica de **boosting**, na qual combinamos modelos fracos para compor um modelo mais forte.