



# DS-001 - Introdução à análise de dados com Python

Prof. Felipe Lobo

## Aula 03 - Introdução à Data Science com Python



- Bibliotecas Python
- Convenções de sintaxe do Python
- Regras sobre variáveis
- Variáveis e comentários
- Operadores Aritméticos
- Funções
- Operadores relacionais
- Variáveis tipo texto

# Bibliotecas Python

A comunidade Python é uma das comunidades de programação mais ativas com um grande número de caixas de ferramentas desenvolvidas.

As caixas de ferramentas Python mais populares para qualquer cientistas de dados são NumPy, SciPy, Pandas e Scikit-Learn.



NumPy3 é a caixa de ferramentas fundamental para computação científica com Python. NumPy fornece, entre outras coisas, suporte para arrays multidimensionais com operações básicas ações sobre eles e funções úteis de álgebra linear. Muitas caixas de ferramentas usam o NumPy representações de array como uma estrutura de dados básica eficiente.

SciPy fornece uma coleção de algoritmos numéricos e caixas de ferramentas específicas de domínio, incluindo sinal processamento, otimização, estatísticas e muito mais. Outra caixa de ferramentas central no SciPy é a biblioteca de plotagem Matplotlib. Esta caixa de ferramentas possui muitas ferramentas para visualização de dados.

# SCIKIT-Learn: aprendizado de máquina em Python



Scikit-learn é uma biblioteca de aprendizado de máquina construída a partir de NumPy, SciPy e Matplotlib.

Scikit-learn oferece ferramentas simples e eficientes para tarefas comuns em análise de dados, como classificação, regressão, agrupamento, redução de dimensionalidade, seleção de modelo, e pré-processamento.



# PANDAS: Biblioteca de Análise de Dados Python

Pandas fornece estruturas de dados e ferramentas de análise de dados de alto desempenho.

A principal característica do Pandas é um objeto DataFrame rápido e eficiente para manipulação de dados com indexação integrada.

A estrutura DataFrame pode ser vista como uma planilha que oferece maneiras muito flexíveis de trabalhar com ele. Você pode transformar facilmente qualquer conjunto de dados em da maneira que desejar, remodelando-o e adicionando ou removendo colunas ou linhas.

# PANDAS: Biblioteca de Análise de Dados Python

Fornece funções de alto desempenho para agregar, mesclar e unir conjuntos de dados.

O Pandas também possui ferramentas para importar e exportar dados de diversos formatos:

- valores separados por vírgula (CSV);
- arquivos de texto;
- Microsoft Excel;
- bancos de dados SQL; e
- formato HDF5 rápido.

# PANDAS: Biblioteca de Análise de Dados Python

Em muitas situações, os dados que você possui nesses formatos não estarão completos ou totalmente estruturados.

Para tais casos, o Pandas oferece tratamento de dados ausentes e alinhamento inteligente de dados.

Além disso, o Pandas fornece uma interface Matplotlib conveniente.



# Importando Bibliotecas Python

```
# Importar a biblioteca  
import numpy as np
```

```
# Importar a biblioteca  
import matplotlib.pyplot as plt
```

```
# Importar a biblioteca  
import pandas as pd
```

# Importando dados para DataFrame

```
# Importar a biblioteca Pandas
import pandas as pd

# Ler os dados do arquivo e colocar os dados no objeto DataFrame

# Para ler os dados de um arquivo CSV
dados = pd.read_csv('pacientes.csv')
# Para ler os dados de um arquivo JSON
dados = pd.read_json('pacientes.json')
# Para ler os dados de um arquivo XML
dados = pd.read_xml('pacientes.XML')
# Para ler os dados de um arquivo Excel
dados = pd.read_excel('pacientes.xlsx')
```

# Importando dados para DataFrame

```
# Importar o arquivo e forçar usar um separador específico (;)
dados = pd.read_csv(arquivo, sep=';')

# Importar o arquivo e forçar que pule na importação a primeira
linha (ou de um conjunto de linhas)
dados = pd.read_csv(arquivo, sep=';', skiprows=1)

# Importar o arquivo e forçar usar um outro tipo de codificação
# Codificações comuns = latin1 / utf8 / cp1252
dados = pd.read_csv(arquivo, sep=';', skiprows=1, encoding='latin1')

# Importar o arquivo e ler apenas algumas colunas
dados = pd.read_csv(arquivo, usecols=[0, 1, 2])

# Para excluir uma coluna da tabela, considere:
# axis = 0 para indicar uma linha
# axis = 1 para indicar uma coluna
dados = dados.drop('UBS', axis=1)
```

# Exibir conteúdo de um DataFrame

```
# Mostrar o conteúdo do DataFrame "dados"  
dados
```

|   | DT_INTERNACAO | DT_ALTA    | DURACAO_INT | GESTACOES | PARTOS | IG_OBSTETRA | IG_PEDIATRA | ALTO_RISCO |
|---|---------------|------------|-------------|-----------|--------|-------------|-------------|------------|
| 0 | 2014-01-20    | 2014-01-21 | 0.768750    | 2         | 1.0    | 38.0        | 38.0        | sim        |
| 1 | 2014-05-21    | 2014-05-22 | 0.773611    | 1         | 0.0    | 36.0        | 36.0        | sim        |
| 2 | 2014-04-13    | 2014-04-14 | 0.798611    | 2         | 1.0    | 39.0        | 39.0        | não        |
| 3 | 2013-12-04    | 2013-12-05 | 0.807639    | 2         | 1.0    | 41.0        | 41.0        | não        |
| 4 | 2013-12-05    | 2013-12-06 | 0.815972    | 1         | 0.0    | 36.0        | 36.0        | não        |

# Série de dados de um DataFrame

```
# Acessar os dados de uma Series (coluna)

# Se o título da coluna não tiver espaços ou caracteres especiais
# Pode-se usar a forma simples:
dados.TIPO_PARTO

# Caso contrário, use a forma padrão:
dados[ 'TIPO_PARTO' ]
```



# Manipulando DataFrame

```
# Mostrar as 5 primeiras linhas e 5 últimas linhas  
dados
```

```
# Mostrar uma amostra aleatória de 10 linhas  
dados.sample(10)
```

```
# Mostrar o início (topo) da lista de dados  
dados.head()
```

```
# Mostrar o fim (cauda) da lista de dados  
dados.tail()
```

# Manipulando DataFrame

```
# Resumo descritivo das colunas numéricas  
dados.describe()
```

|              | DURACAO_INT | GESTACOES   | PARTOS      | IG_OBSTETRA | IG_PEDIATRA | CESAREAS_PREVIAS | PESO_NASCER |
|--------------|-------------|-------------|-------------|-------------|-------------|------------------|-------------|
| <b>count</b> | 1708.000000 | 1708.000000 | 1707.000000 | 1686.000000 | 1704.000000 | 1701.000000      | 1680.000000 |
| <b>mean</b>  | 3.013466    | 2.175059    | 0.95372     | 37.901542   | 37.957746   | 0.262199         | 2977.958929 |
| <b>std</b>   | 4.350403    | 1.449129    | 1.22674     | 3.181517    | 3.113337    | 0.600519         | 691.185194  |
| <b>min</b>   | 1.000000    | 1.000000    | 0.00000     | 19.000000   | 19.000000   | 0.000000         | 270.000000  |
| <b>25%</b>   | 2.000000    | 1.000000    | 0.00000     | 37.000000   | 37.000000   | 0.000000         | 2710.000000 |
| <b>50%</b>   | 2.000000    | 2.000000    | 1.00000     | 39.000000   | 39.000000   | 0.000000         | 3065.000000 |
| <b>75%</b>   | 3.000000    | 3.000000    | 1.00000     | 40.000000   | 40.000000   | 0.000000         | 3390.000000 |
| <b>max</b>   | 63.000000   | 17.000000   | 10.00000    | 42.000000   | 42.000000   | 5.000000         | 5625.000000 |



# ATÉ A PRÓXIMA AULA!

Prof. Felipe Lobo



 [felipe.lobo@ufr.br](mailto:felipe.lobo@ufr.br)

