



DS-001 – Gerenciamento de Dados para Análise

Prof. Nome do Professor

Aula 01 – Pré-processamento



- Biblioteca Pandas

Padrão dominante para aplicações Python orientadas a dados. Possui duas estruturas de dados: **Series**, que trabalha com informações em 1 Dimensão, e **DataFrame**, que possui 2 Dimensões. Na prática, o DataFrame é uma coleção de objetos Series.

**Bibliotecas são conjuntos de recursos que precisam ser importados para um projeto, para que estejam à disposição do cientista de dados.*

```
import pandas as pd
```

Principais recursos do Pandas

- ▶ `pd.read_csv(r'/content/nome_arquivo.csv')`

Permite importar um arquivo para o projeto de ciência de dados. É similar a abrir um arquivo em uma planilha eletrônica.

- ▶ `DataFrame.head(valor)`

Permite consultar um número X de linhas do DataFrame, a contar da primeira, conforme valor informado pelo usuário. Se nada for informado entre parênteses, irá retornar as 05 primeiras linhas.

- ▶ `DataFrame.tail(valor)`

Permite consultar um número X de linhas do DataFrame, a contar da última, conforme valor informado pelo usuário. Se nada for informado entre parênteses, irá retornar as 05 últimas linhas.

- ▶ `=`

Comando de atribuição. É possível copiar o conteúdo de um DataFrame para outro, a partir deste operador.

- ▶ `pd.DataFrame(valor)`

Permite criar um DataFrame a partir de outro já existente ou de uma lista de listas ou de objetos Series que tenham sido previamente concatenadas. Ao ser usado, cria no DataFrame um índice cuja primeira linha corresponde à posição 0.

- ▶ `Dataframe['nome_coluna'].unique()`

Permite consultar valores exclusivos (não duplicados) de uma coluna de um DataFrame, que tenha sido indicada pelo cientista de dados.

- ▶ `Dataframe.isnull().any()`

Permite examinar se existem dados nulos em um DataFrame específico.

- ▶ `Dataframe.isna().any()`

Comando que produz os mesmos resultados que o anterior.

- ▶ DataFrame.**dropna**()

Permite remover linhas cujas células possuem um ou mais casos de dados nulos ou que não são números, quando deveriam ser.

- ▶ Dataframe.**info**()

Permite avaliar os nomes das colunas, o tipo de dados que possuem e o total de linhas sem objetos nulos.

- ▶ Dataframe.**apply**(nome_funcao)

Pode aplicar a um DataFrame uma função específica, podendo ser usada para a criação de novas colunas no DataFrame.

Principais recursos do Pandas

- ▶ `Dataframe.sample(valor)`

Retorna uma amostra aleatória de linhas do DataFrame conforme o valor determinado pelo cientista de dados. Se nada for informado, o método retorna 1 linha aleatória.

- ▶ `Dataframe.query("termo_para_buscar' in nome_coluna")`

Permite buscar um termo determinado em uma coluna específica do DataFrame, retornando as linhas cuja coluna indicada possui esse termo.

- ▶ `Dataframe.query("nome_coluna == valor")`

Retorna as linhas do DataFrame cuja coluna indicada pelo cientista de dados corresponde a um valor informado por ele.

- ▶ `Dataframe['nome_coluna'].value_counts(normalize=False)`

Contabiliza o total de valores de cada categoria presente em uma coluna passada como referência. Se o parâmetro `normalize` for configurado como `True`, calcula o percentual.

ATÉ A PRÓXIMA AULA!

Prof. Marcelo Henklain

 sites.google.com/view/profmarcelohenklain

 marcelo.henklain@ufrr.br

