





DS-003 – Análises básicas de dados para área da saúde I

Prof. Marcelo Henklain

Aula 01.1 – Aprendizado de Máquina







Introdução ao Aprendizado de Máquina


Aprendizado de Máquina

Esta árvore nos permite **classificar** quem gosta ou não de DS.




A reta verde nos ajuda a **prever** uma nota em função de horas de estudo. A curva vermelha faz o mesmo trabalho. Qual o melhor modelo?





A reta não representa os dados reais com perfeição. Por isso, dizemos que tem **viés**.




A curva representa os dados reais com perfeição. Por isso, dizemos que tem baixo **viés**.

Predição com base na reta verde, a partir dos dados usados para criação do modelo.

↑
Realidade

↑
Modelo




Aprendizado de Máquina

Predição com base na reta verde, com base nos dados usados para criação do modelo.

Total de **erro** nas predições

↑
Realidade

↑
Modelo




Aprendizado de Máquina

Predição com base na reta verde, com base nos dados usados para criação do modelo.

↑
Realidade

↑
Modelo



Total de **erro** nas predições




Aprendizado de Máquina

Predição com base na reta verde, com base nos dados usados para criação do modelo.

↑
Realidade

↑
Modelo



Total de **erro** nas predições




Aprendizado de Máquina

Predição com base na reta verde, com base nos dados usados para criação do modelo.

↑
Realidade


↑
Modelo



Total de **erro** nas predições



Sabemos que a **curva vermelha** tem **baixo viés**.




Total de **erro** nas previsões

Erro = 0
em todos os casos


O problema é que **não queremos prever algo que já conhecemos**. Por isso precisamos testar com novos dados.

Qual o **melhor modelo** considerando os **novos dados** (pontos vermelhos)?




↑
Realidade

↑
Modelo



Total de **erro** nas
predições







Total de **erro** nas
predições




Embora a curva seja perfeita em relação aos dados de treino, obteve um resultado pior com os dados de teste. A reta foi um **modelo melhor**.



Total de **erro** nas previsões







Total de **erro** nas
predições

Curva

Reta







Total de **erro** nas
predições

Curva

Reta





Atenção: encontrar um modelo perfeito em relação aos dados de treino não é promissor. Chamamos isso de **sobreajuste / overfitting**.




A curva varia entre os dados de teste e de treino. Por isso dizemos que tem **alta variação**. Já a reta tem **pouca variação**.

Aprendizado de Máquina






overfitting



underfitting



Good balance